

Predicción de precios de vivienda

Ames Housing · Proyecto Final

Ricardo Farfan - 21003210 , Rodrigo Solis - 21002223, Gabriela Subuyu - 21001134

El problema y los datos

Predecir el precio de venta (SalePrice) de 220 viviendas en Ames, Iowa, a partir de 79 características físicas, de ubicación y de venta.

880

viviendas de entrenamiento
(con SalePrice)

220

viviendas de test
(a predecir)



81

variables
(38 numéricas · 43 categóricas)

RMSE

métrica oficial en USD


SalePrice se modela en escala logarítmica



Asimetría: 2.03 $\rightarrow$ -0.06 tras aplicar log.

- La distribución está sesgada a la derecha: pocas casas muy caras dominarán el ajuste.
- $\log(\text{SalePrice})$ es casi simétrica: cumple mejor los supuestos de los modelos lineales.
- Minimizar el error en log equivale a penalizar el error porcentual, no el absoluto.
- Las predicciones se des-transforman con $\exp()$ y el RMSE se evalúa en dólares.

Valores faltantes



Estructurales → “None” / 0


PoolQC (99%), Alley (93%), Fence (82%), FireplaceQu, Garage*, Bsmt*... El NA significa que la casa no tiene esa característica: es señal, no ruido.

Genuinos → imputación informada

LotFrontage (19%): mediana por vecindario.
GarageYrBlt: se usa YearBuilt. Electrical (1 caso): moda.
Resultado: 0 NA en train y test.


Calidad y superficie mandan sobre el precio

Calidad general (OverallQual) vs. Precio



OverallQual $r = 0.79$

Área habitable (GrLivArea) vs. Precio



GrLivArea $r = 0.71$

También destacan TotalBsmtSF (0.65), GarageCars (0.65) y X1stFlrSF (0.63).

Limpieza e ingeniería de variables



Outlier eliminado (solo 1)

Id 524: 4,676 pies² pero \$184,750 — venta no representativa. Train: 880 → 879 filas.



Consistencia train/test

codificación sobre el dataset combinado: mismos niveles de factor y mismas 264 columnas dummy en ambos conjuntos.



Datasets finales

train_clean: 879 × 91 · test_clean: 220 × 90.

10 VARIABLES NUEVAS

TotalSF — sótano + 1er + 2do piso: el tamaño total en una sola variable

TotalBaths — baños completos + 0.5·medios (incluye sótano)

HouseAge / RemodAge — antigüedad y años desde remodelación al vender


TotalPorchSF — consolida 5 columnas de porche/terraza

Banderas 0/1 — Remodelada, TienePiscina, TieneGaraje, TieneSótano, Tiene2doPiso

Modelos

Comenzamos con modelos simples como regresion lineal OLS y regularizaciones Ridge, LASSO y ElasticNet

La regularización reduce y estabiliza el error



OLS sobreajusta

RMSE alto y muy variable entre folds (sd ~7,100).

Ridge/Lasso penalizan coeficientes

el error cae ~6,000 USD

Elastic-Net ($\alpha=0.5$) es el mejor

combina la selección de variables del Lasso con la estabilidad del Ridge. RMSE CV $\approx$ \$22,100.

Descubrimos que una sola casa afectaba por completo nuestro RMSE



La casa Id 1299 del test: 5,642 pies² habitables (máximo absoluto), calidad 10, barrio Edwards. Está fuera del rango aprendido: el máximo del train es \$755,000.

Los modelos lineales extrapolan: la predijeron entre \$2.3M y \$3.0M

Aporte de ese único error al RMSE

Como el RMSE eleva los errores al cuadrado, un error de ~\$2.8M en una casa define casi todo el RMSE de nuestro submission.

Primeras mejoras de modelos




Modelos de árboles

No pueden predecir fuera del rango de entrenamiento, esto los hace buenos para evitar extrapolaciones.

- Random Forest: RMSE CV $\sim 27,300$ y predicción máxima $\sim 511k$.
- XGBoost: RMSE CV $\sim 23,800$ y predicción máxima. $\sim 510-640k$.
- Algo peores en casas normales, pero evitan el error enorme de extrapolacion.

Modelo final: Blend + regla de extrapolación por comparables



Peso w elegido al ver cual daba el menor RMSE.

Modelo "Blend" o mezcla

Lo que hicimos fue combinar un modelo con un peso (w) de 70% de elasticnet que era bueno para predecir las casas normales y 30% XGBoost que era bueno evitando extrapolaciones.

REGLA DERIVADA DE LOS DATOS

- 1. Umbral:** toda casa del test con GrLivArea mayor al máximo del train está fuera del rango aprendido.
- 2. Comparable:** se le asigna el precio del vecino más cercano por tamaño y misma condición de venta.

Conclusiones



La métrica es lo más importante

Con RMSE, un solo error extremo puede definir el resultado completo. Qué fue lo que nos paso con la casa outlier.



Combinar los mejores modelos

Elastic-Net era muy preciso en casas normales y XGBoost que no extrapola. Este modelo blend ($w=0.70$) fue lo que nos dio los mejores resultados



Correcciones basadas en los datos

La regla de comparables fue lo que más ayuda nos dio para resolver casos de casas muy fuera de lo común